Міністерство освіти і науки України
Львівський національний університет імені Івана Франка

Кафедра радіофізики та комп’ютерних технологій

Любунь З.

МЕТОДИЧНІ ВКАЗІВКИ ДО ВИКОНАННЯ ЛАБОРАТОРНИХ РОБІТ

з курсу “Аналіз даних”
що викладається в межах ОПП «Комп’ютерні науки» першого (бакалаврського) рівня вищої освіти для здобувачів з спеціальності
122 «Комп’ютерні науки»

Львів 2024

Вступ

Лабораторний практикум є складовою частиною методичного забезпечення дисципліни “Аналіз даних” першого (бакалаврського) рівня вищої освіти для здобувачів з спеціальності 122 “Комп’ютерні науки”.

Метою практикуму є реалізація базових алгоритмів аналізу даних (АД) з метою кращого засвоєння теоретичного матеріалу. Виконання лабораторних робіт дає можливість на практиці побачити та зрозуміти особливості, переваги та недоліки застосування конкретних методів аналізу даних.

Багато задач АД передбачають підбір конкретного алгоритму аналізу, що потребує певного досвіду, котрий студент може отримати лише застосовуючи окремі алгоритми аналізу до реальних та модельних задач.

Окрім того, часто самі алгоритми передбачають вибір оптимальних для даного завдання значень параметрів. Виконуючи завдання, студент проводить дослідження роботи методу за різних значень параметрів і вчиться на основі отриманих результатів вибрати їх оптимальне значення. У процесі виконання лабораторних робіт важливим є набуття навичок аналізу результатів роботи програми з погляду як правильності реалізації алгоритму аналізу даних, так і ефективності роботи самого алгоритму аналізу.

Метою практикуму, крім засвоєння методів АД, є закріплення навичок реалізації різних алгоритмів конкретною мовою програмування. Мову програмування вибирає сам студент.

У практикумі не передбачено використання готових комерційних пакетів АД. Більша користь для підготовки студентів за цією спеціальністю є написання власних, хоч і простіших та менш ефективних програм аналізу даних. Такий підхід дає можливість студентам набути навичок як у сфері аналізу даних, так і в програмуванні різних алгоритмів.

Розгляд готових комерційних пакетів аналізу даних може бути предметом наступних курсів, у яких студент уже зі знання предмету може більш свідомо користуватися готовими пакетами прикладних програм аналізу даних.

При виконанні завдань дозволяється використання такого нового інструменту як систем штучного інтелекту (ШІ). При цьому вимагається повне розуміння коду програми та використаних алгоритмів аналізу, здатність модифікувати програмний код.

Лабораторна робота № 1.
Реалізація елементарних алгоритмів аналізу даних.

Зазвичай першу лабораторну роботу проводять тоді, коли матеріал ще не викладений студентові, тому є потреба у вступній лабораторній роботі, котра опирається на попередні знання студентів і стосується аналізу даних. Оскільки роботу виконують на першому занятті без підготовки, вона дає можливість визначити рівень підготовки студента з огляду на рівень володіння довільною мовою програмування як інструментом для реалізації алгоритмів АД. Перелік вступних завдань та вимоги до програм подані в таблиці 1.1.

Таблиця 1.1
Перелік завдань

№ п.п.	Умова	Вимоги до програми
1.	Визначити чи є заданий трикутник прямокутним на основі заданих довжин сторін	Програма повинна мати зручний віконний інтерфейс для вводу вихідних даних та виводу

		результатів обчислень
2.	Визначити чи введене число є: додатнім, цілим, парним (у випадку цілого числа)	Програма повинна мати зручний віконний інтерфейс для вводу вихідних даних та виводу результатів обчислень
3.	Посортувати в порядку зростання 10 випадкових чисел	Не використовувати готові оператори сортування. Вивести числа до і після сортування
4.	Посортувати в порядку спадання 10 випадкових чисел	Не використовувати готові оператори сортування. Вивести числа до і після сортування

5.	Знайти найбільше число із 10 випадкових чисел	Не використовувати готові оператори пошуку. Вивести всі числа та найбільше з них
6.	Знайти найменше число із 10 випадкових чисел	Не використовувати готові оператори пошуку. Вивести всі числа та найменше з них
7.	Задане речення, яке містить (чи ні) певне ключове слово. Написати програму пошуку заданого ключового слова	Програма повинна містити вікно вводу речення та ключового слова
8.	Задана пронумерована послідовність N додатних чисел. Знайти кількість чисел K, які в сумі дають значення більше, ніж задане число S	Програма повинна містити вікно вводу послідовності чисел та значення S
9.	Написати програму розв’язку квадратного рівняння	Програма повинна містити вікно вводу коефіцієнтів рівняння та виводу результатів
10.	Знайти два найменші числа із 10 випадкових чисел	Не використовувати готові оператори пошуку. Вивести всі числа та два найменші з них
11.	Знайти два найбільші числа із 10 випадкових чисел	Не використовувати готові оператори пошуку. Вивести всі числа та два найбільші з них
12.	З послідовності 10 чисел знайти всі числа більші за їх середнє значення	Вивести всі числа, їх середнє значення та всі числа більші від нього
13.	З послідовності 10 чисел знайти всі числа менші за їх середнє значення	Вивести всі числа, їх середнє значення та всі числа менші від нього

Набір випадкових чисел треба отримати за допомогою стандартного генератора випадкових чисел з рівномірним розподілом, який є в кожній мові програмування.

Лабораторна робота № 2.
Методи первісної обробки даних.

Короткі теоретичні відомості.

Необхідність попередньої обробки даних зумовлена тим, що під час отримання вихідних даних різним способом можливе їх спотворення. Попередня обробка даних дає змогу підвищити як якість аналізу даних, так і якість самих даних. Результати вимірювань чи досліджень часто спотворені завадами. В масиві даних, які аналізуються, можуть бути недостовірні, помилкові дані отримані внаслідок неуважності чи некомпетентності збирача даних чи просто промахи вимірювання.

Суть попередньої обробки даних полягає у відсіюванні грубих похибок і оцінюванні достовірності результатів вимірювань.

Терміни очищення та згладжування аналогічні до терміна фільтрація даних, котрий використовують в радіоелектроніці. Тому алгоритми згладжування та очищення даних можна розглядати як певні цифрові фільтри.

У процесі використання статистичних методів АД завданням попередньої обробки даних є перевірка відповідності результатів вимірювання нормальному закону і визначення параметрів цього розподілу. Якщо відгук суперечить нормальному розподілу, то треба визначити, якому закону розподілу підлягають дослідні дані або, якщо це можливо, перетворити досліджуваний розподіл до нормального вигляду.

До причин, що потребують очищення даних можна віднести таке:

1. Суперечливість інформації. Необхідно визначити, яка інформація є суперечливою і видалити її, а краще виправити;
2. Прогалини в даних. Використовують методи апроксимації або визначають найімовірніші дані на основі всього масиву даних;
3. Аномальні значення. Зазвичай, аномальні значення видаляють або заміняють на найближче значення;
4. Шум (завади, похибки вимірювань). Використовують різні методи фільтрації (згладжування) даних.

Розглянемо низку методів, котрі дають можливість частково позбутися шуму[1,2].

Метод обновлюваної середньої.

При згладжуванні цим методом у кожній точці на часовій осі виміряне значення замінюють на середнє, розраховане на цей момент часу.

Перше значення збігається з x_1: $\overline{x}_1 = x_1$. Друге значення обчислюють за рекурентною формулою: $\overline{x}_n = \overline{x}_{n-1} + \frac{1}{n}(x_n - \overline{x}_{n-1})$.

Вихідні дані показані на рисунку 2.1 пунктирною лінією, а результати згладжування (фільтрації) – суцільною лінією.

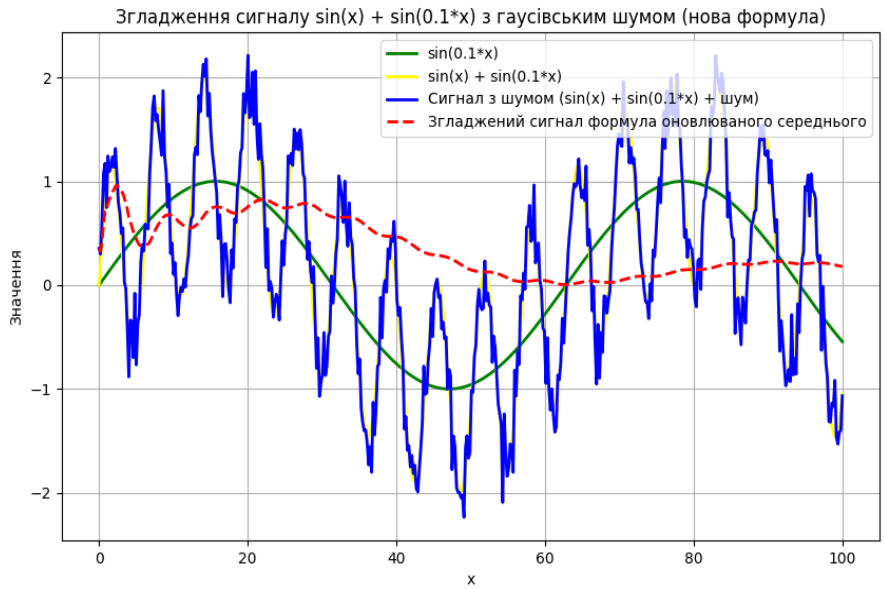

Рис. 2.1. Вихідні дані та результати згладжування методом обновлюваної середньої.

Метод ковзної середньої.

Метод полягає в послідовному усередненні на певному інтервалі значень вимірюваної величини x.

Операцію згладжування виконують за формулою:

$$\overline{x}_{i+\frac{l}{2}} = \frac{1}{l+1}\sum_{k=0}^{l} x_{i+k} ,$$

де i – номер інтервалу; $l+1$ – кількість вимірювань у i – тому інтервалі; $i+\frac{l}{2}$ – номер замінюваного вимірювання. Якщо попереднє оцінювання виконано невдало і після згладжування залишаються завади, отримані дані знову можна усереднювати і робити це багаторазово, до бажаного результату.

Результати згладжування при $l = 2$ показані на рисунку 2.2.

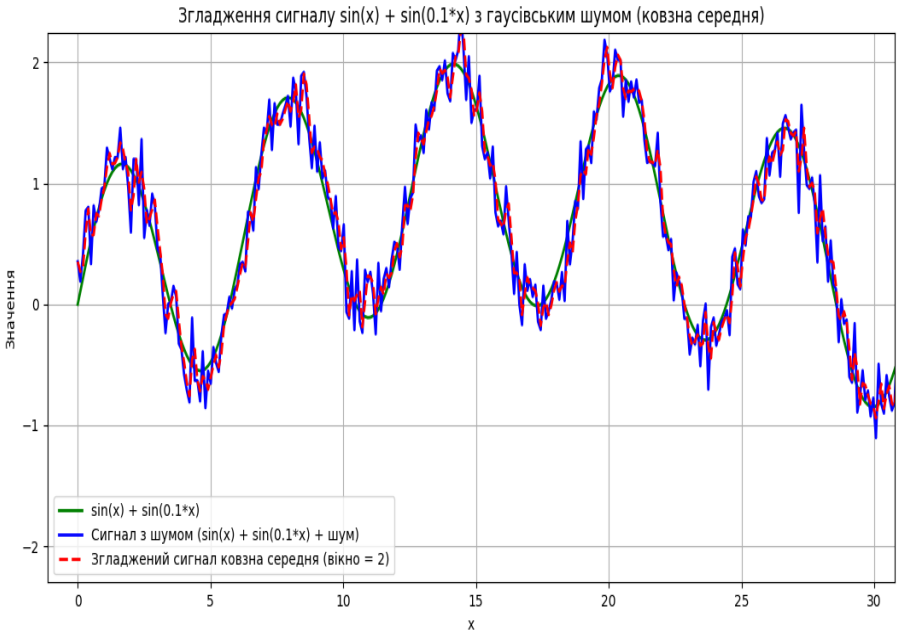

Рис. 2.2. Результати згладжування при $l = 2$.

Можливий варіант згладжування, коли інтервали згладжування не перекриваються. Очевидно, за такого способу згладжування при заданому вікні усереднення перші та останні точки не можуть бути отримані. В цьому випадку якщо недостатньо значень, беремо середнє доступних значень.

Метод експоненційного згладжування.

Порівняно з попередніми методами фільтрації цей метод має найширші можливості завдяки наявності параметру α, підбір якого дає змогу вибрати оптимальну для цього типу даних формулу згладжування. Тут використовують такі формули:

$\overline{x}_n = \alpha x_n + (1-\alpha)\overline{x}_{n-1}$ або $\overline{x}_n = \overline{x}_{n-1} + \alpha(x_n - \overline{x}_{n-1})$,

де α - параметр згладжування, який вибирають в діапазоні 0…1.

За малих α, близьких до 0 α, сукупність обчислених середніх відобразить низькочастотні зміни вимірюваної змінної, позбавивши їх швидкозмінних перешкод.

Якщо обрана величина α близька до 1 (наприклад, становить 0,6), то згладжування буде мало інерційним, значення $\overline{x}_n$ ближчими до вимірюваних значень x, а за $\alpha = 1$ отримані значення співпадатимуть з вихідними і ніякої фільтрації не відбуватиметься.

Завдання.

Реалізувати алгоритми первісного опрацювання даних для послідовності значень, отриманих у результаті табуляції функції $f(x) = f_n(x) + random$ на інтервалі $x \in [0 \div 10]$ з кроком 0.1, де $round$ випадкове число з Гаусівським розподілом із нульовим середнім та стандартним відхиленням 0.2. Функція $f_n(x)$ відповідає номеру студента в журналі обліку і вибирається з таблиці 2.1.

В програмі передбачити можливість зміни інтервалу табуляції, кроку табуляції заданої функції та параметрів шуму.

Таблиця 2.1

№ п.п.	$f_n(x)$	№ п.п.	$f_n(x)$
1.	$\sin(0.1x)+\sin(x)$	11.	$\sin^2(0.1x)+\sin^2(x)$
2.	$\sin(0.1x)+\cos(x)$	12.	$\sin(0.1x)+\sin^2(x)$
3.	$\cos(0.1x)+\sin(x)$	13.	$\sin^2(0.1x)*\sin(x)$
4.	$\cos(0.1x)+\cos(x)$	14.	$\sin(0.1x)*\sin^2(x)$
5.	$\sin(0.1x)*\sin(x)$	15.	$\cos^2(0.1x)*\sin(x)$

Закінчення табл. 2.1

6.	$\sin(0.1x)*\cos(x)$	16.	$\cos(0.1x)*\sin^2(x)$
7.	$\cos(0.1x)*\sin(x)$	17.	$\cos^2(0.1x)*\cos(x)$
8.	$\cos(0.1x)*\cos(x)$	18.	$\cos(0.1x)*\cos^2(x)$
9.	$\sin^2(0.1x)+\sin^2(x)$	19.	$\sin^2(0.1x)\times\sin^2(x)$
10.	$\sin^2(0.1x)+\sin(x)$	20.	$\cos^2(0.1x)*\cos^2(x)$

Зміст звіту по лабораторній роботі.

Візуально представити результати згладжування для всіх методів. На зображенні необхідно представити сигнал без шуму, зашумлений сигнал та результати згладжування.

Для методів ковзного та експоненціального згладжування провести дослідження при різних значеннях параметрів та вибрати оптимальний варіант. Вибір обґрунтувати.

Зробити загальні висновки щодо використання розглянутих алгоритмів для опрацювання сигналів.

Література

1. Попередня обробка експериментальних даних. [Електронний ресурс]. – Режим доступу: http://wiki.tntu.edu.ua/Попередня_обробка експериментальних_даних. – Дата звернення: 14.04.2015.
2. Олійник А. О. Інтелектуальний аналіз даних : навчальний посібник. Запоріжжя : ЗНТУ, 2012. 278 с .
3. Processing Sensor Signal Under Low Values of Signal to Noise Ratio Liubun, Z., Bryk, B., Mandziy, V., .Kalivoshka, B., Velhosh, S. 2023 IEEE 13th International Conference on Electronics and Information Technologies, ELIT 2023 – Proceedings, 2023, pp. 73–76.

Лабораторна робота №3.
Використання методу найменших квадратів для згладжування даних

Короткі теоретичні відомості.

Метод найменших квадратів дає найкращий результат тоді, коли похибка даних є порівняно невеликою. Інакше потрібне проведення попередньої обробки експериментальних даних, яка полягає в такому: вихідні записи випадкових величин згладжують певним способом, що дає змогу виявити основну тенденцію у їхній зміні.

У випадку опрацювання економічних даних чи результатів опитувань або вимірювань використовують емпіричну формулу у вигляді степеневого полінома:

$$y = F(x) = a_m x^{m-1} + a_{m-1} x^{m-2} + a_2 x + a_1 \qquad (3.1)$$

де $a_{m-1},\ a_{m-2}, \ldots a_2,\ a_1$ — невідомі коефіцієнти. Треба знайти такі значення коефіцієнтів, за яких крива (3.1) якомога ближче проходитиме до всіх вихідних (експериментальних) точок $(y_1, x_1), (y_2, x_2),\ \ldots,\ (y_n, x_n)$.

За методом найменших квадратів найкращі значення коефіцієнтів ті, для яких сума квадратів відхилень

$$S(a_1, \ldots a_{m-1}) = \sum_{i=1}^{n} (y_i - F(x_1; a_1, \ldots a_{m-1}))^2 \qquad (3.2)$$

експериментальних даних від обчислених за емпіричною формулою (3.1) найменша.

Необхідною умовою мінімуму функції багатьох змінних є нульове значення її частинних похідних:

$$\frac{\partial S}{\partial a_k} = 0 \text{, для всіх } k = 1,\ 2,\ m-1.$$

Диференціюючи вираз (3.2) за невідомими параметрами, матимемо відносно них систему рівнянь:

$$\begin{cases} \sum_{i=1}^{n} \left(y_i - F\left(x_i;\, a_1,\, a_2, \ldots, a_m\right)\right) \cdot \dfrac{\partial F\left(x_i;\, a_1, \ldots, a_m\right)}{\partial a_1} = 0, \\ \sum_{i=1}^{n} \left(y_i - F\left(x_i;\, a_1, \ldots, a_m\right)\right) \cdot \dfrac{\partial F\left(x_i;\, a_1, \ldots, a_m\right)}{\partial a_2} = 0, \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ \sum_{i=1}^{n} \left(y_i - F\left(x_i;\, a_1, \ldots, a_m\right)\right) \cdot \dfrac{\partial F\left(x_i;\, a_1, \ldots, a_m\right)}{\partial a_m} = 0. \end{cases}$$

Розглянемо випадок використання лінійної емпіричної формули. Нехай між даними $(x_i,\, y_i)\quad (i = 1, 2, \ldots, n)$ існує лінійна залежність. Шукатимемо емпіричну формулу у вигляді:

$$y = a_2 x + a_1, \qquad (3.3)$$

де коефіцієнти a_2 і a_1 невідомі.

Знайдемо значення a_2 і a_1, за яких функція $S(a_2, a_1) = \sum_{i=1}^{n} (y_i - a_2 x_i - a_1)^2$ буде мінімальною. Щоб знайти ці значення, прирівняємо до нуля частинні похідні функції $S(a_2, a_1)$:

$$\begin{cases} \dfrac{\partial S}{\partial a_2} = 2\sum_{i=1}^{n} (y_i - a_2 x_i - a_1)(-x_i) = 0, \\ \dfrac{\partial S}{\partial a_1} = 2\sum_{i=1}^{n} (y_i - a_2 x_i - a_1)(-1) = 0. \end{cases} \qquad (3.4)$$

Звідси, врахувавши, що $\sum_{i=1}^{n} a_1 = n a_1$, маємо

$$\begin{cases} a_2 \sum_{i=1}^{n} x_i^2 + a_1 \sum_{i=1}^{n} x_i = \sum_{i=1}^{n} x_i y_i, \\ a_2 \sum_{i=1}^{n} x_i + n a_1 = \sum_{i=1}^{n} y_i. \end{cases} \qquad (3.5)$$

Розв'язавши відносно a_2 і a_1 останню систему, знайдемо

$$a_2 = \frac{n\sum_{i=1}^{n} x_i y_i - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n\sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i\right)^2}, \qquad (3.6)$$

$$a_1 = \frac{\sum_{i=1}^{n} y_i \sum_{i=1}^{n} x_i^2 - \sum_{i=1}^{n} x_i y_i \sum_{i=1}^{n} x_i}{n\sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i\right)^2}. \qquad (3.7)$$

Розглянемо випадок квадратичної емпіричної залежності. Нехай функціональна залежність між x та y — квадратична. Шукатимемо емпіричну формулу у вигляді:

$$y = a_3 x^2 + a_2 x + a_1. \qquad (3.8)$$

Тоді формулу (3.2) запишемо так:

$$S(a_3, a_2, a_1) = \sum_{i=1}^{n} (y_i - a_3 x_i^2 - a_2 x_i - a_1)^2.$$

Для обчислення коефіцієнтів a_3, a_2, a_1, за яких функція $S\left(a_3, a_2, a_1\right)$ мінімальна, обчислимо частинні похідні $\frac{\partial S}{\partial a_3}$, $\frac{\partial S}{\partial a_2}$, $\frac{\partial S}{\partial a_1}$ і прирівняємо їх до нуля. У результаті отримаємо систему рівнянь:

$$\begin{cases} \sum_{i=1}^{n}\left(y_i - a_3 x_i^2 - a_2 x_i - a_1\right)\cdot x_i^2 = 0, \\ \sum_{i=1}^{n}\left(y_i - a_3 x_i^2 - a_2 x_i - a_1\right)\cdot x_i = 0, \\ \sum_{i=1}^{n}\left(y_i - a_3 x_i^2 - a_2 x_i - a_1\right) = 0. \end{cases}$$

Після рівносильних перетворень маємо систему:

$$\begin{cases} a_3\sum_{i=1}^{n} x_i^4 + a_2\sum_{s=1}^{n} x_i^3 + a_1\sum_{i=1}^{n} x_i^2 = \sum_{i=1}^{n} x_i^2 y_i, \\ a_3\sum_{i=1}^{n} x_i^3 + a_2\sum_{s=1}^{n} x_i^2 + a_1\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} x_i y_i, \\ a_3\sum_{i=1}^{n} x_i^2 + a_2\sum_{s=1}^{n} x_i + na_1 = \sum_{i=1}^{n} y_i. \end{cases} \quad (3.9)$$

Розв’язок цієї системи визначає єдину параболу, яка краще від усіх апроксимує вихідну послідовність даних.

Завдання.

Реалізувати програму первісної обробки даних з використанням методу найменших квадратів для послідовності значень отриманих у результаті табуляції функції $f(x) = f_n(x) + \alpha * round$ при різних значеннях α на інтервалі $x \in [-5 \div 5]$ з кроком 0.1, де $round$ випадкове число з Гаусівським розподілом із нульовим середнім та стандартним відхиленням 0.2. Функція $f_n(x)$ відповідає номеру студента в журналі обліку і вибирається з таблиці 3.1.

Програма повинна реалізувати як лінійний випадок, так і квадратичну емпіричну функцію.

Програма повинна забезпечувати зміну інтервалу та кроку табуляції функції.

Наступне завдання на основі попередньої програми провести апроксимацію сигналу з шумами вибравши оптимальне значення степеня поліному апроксимації. Вихідні дані для аналізу приведені у розділі файли відповідної команди Teams: Дані_лаб3 і вибираються згідно номера студента у журналі обліку.

Таблиця 3.1

Таблиця вихідних функцій.

№ п.п.	$f_n(x)$	№ п.п.	$f_n(x)$
1.	$-3x^2+5x-4$	17.	$-x^2+x-4$
2.	$0.9*x^2-5x+0.3$	18.	$0.1x^2-0.5x+0.3$
3.	$4x-2x^2-0.9$	19.	$x-x^2-0.9$
4.	$2-3x-0.2x^2$	20.	$20-6x-0.2x^2$
5.	$2x-0,4x^2$	21.	$x-0,1x^2$
6.	$8-2x$	22.	$1-0.2x$
7.	$-0.3x^2+5x-4$	23	$-3x^2+x-4$
8.	$0.9*x^2-2x+0.1$	24.	$9x^2-8x+0.1$
9.	$0.4x-x^2-0.9$	25.	$0.1x-x^2-0.1$
10.	$2-x-2x^2$	26.	$1-2x-2x^2$
11.	$x-0,9x^2$	27.	$2x-0,4x^2$
12.	$0.8-4x$	28.	$8-2x$
13.	$-x^2+x-1$	29.	$-5x^2+0.1x$
14.	$3-4x-2x^2$	30.	$3*x^2-4x+3$
15.	$2x-3x^2-9$	31.	$5x^2+5x-3$
16.	$x^2-0.5x+0.1$	32.	$x^2+0.1$

Зміст звіту по лабораторній роботі:

Привести знайдені коефіцієнти полінома методом найменших квадратів і порівняти їх з реальними при різних значеннях шумів для сигналів з таблиці 3.1. Результати оформити у вигляді таблиць 3.2, 3.3.

Привести графіки, на яких повинні бути зображені такі залежності:

1. Вигляд вихідної функції $f_n(x)$ та зашумлених функцій при $\alpha = 1, 10, 100$
2. Вигляд вихідної функції $f_n(x)$ та функцій отриманих в результаті згладжування МНК для обох емпіричних формул при різних значеннях α.

Привести результати апроксимації даних (Дані_лаб3) з шумами при різних значеннях степеня поліному апроксимації та при оптимальному степені поліному.

В додатку необхідно привести вихідний код програми.

Таблиця 3.2

Метод найменших квадратів (лінійна емпірична формула)

Вихідна функція	Лінійна емпірична формула		
	$\alpha = 1$	$\alpha = 10$	$\alpha = 100$

	Значення	Значення	Похибка%	Значення	Похибка%	Значення	Похибка%
a_1							
a_2							

Таблиця 3.3

Метод найменших квадратів (квадратична емпірична формула)

Вихідна функція		Квадратична емпірична формула					
		$\alpha = 1$		$\alpha = 10$		$\alpha = 100$	
	Значення	Значення	Похибка%	Значення	Похибка%	Значення	Похибка%
a_1							
a_2							
a_3							

Література

1. Хвищун І. О. Програмування і математичне моделювання/І. О. Хвищун/ Підручник. – Л: Видавничий Дім «Ін Юре», 2007. – 544 с.: іл.

2. Метод найменших квадратів. [Електронний ресурс]. – Режим доступу: http://uk.wikipedia.org/wiki /Метод_найменших_квадратів. – Дата звернення: 14.04.2015.

Лабораторна робота № 4.
Візуалізація даних.

Короткі теоретичні відомості.

Ідея візуалізації даних ґрунтується на здатності людини майже миттєво сприймати (аналізувати) величезний обсяг інформації. Ідеться про графічні зображення. Варто зауважити, що така здатність людини фізіологічно обумовлена. Кількість рецепторів людського ока приблизно дорівнює 10^{11}, від кожного з них сигнал передається по приблизно 10^{9} волокнах у мозок. Ці сигнали активізують ділянки мозку і ми сприймаємо графічне зображення об’єкта. Таким способом мозок здатен опрацьовувати колосальні обсяги інформації в кожний момент часу. Окрім того, людині властиве асоціативне мислення, що дає можливість не тільки сприймати графічні об’єкти, а і проводити їх аналіз, наприклад, вирішувати задачу розпізнавання.

Очевидно, що способи візуалізації даних суттєво залежать від предметної галузі АД. Візуалізацію даних використовують чи не у всіх сферах знань, від графіків математичних функцій та фізичних залежностей до різного типу діаграм в економіці та результатів томографії в медицині. На рисунках 4.1 – 4.2 показані деякі приклади візуалізації даних.

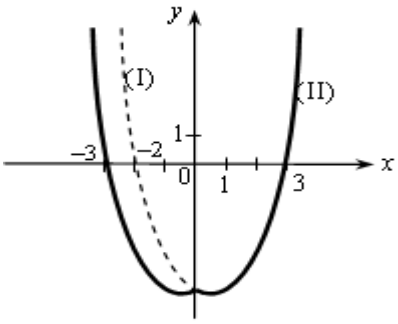

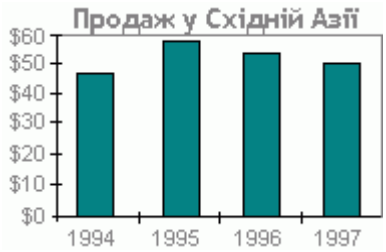

Графік математичної функції Стовпчаста діаграма

Рис. 4.1. Приклади візуалізації даних

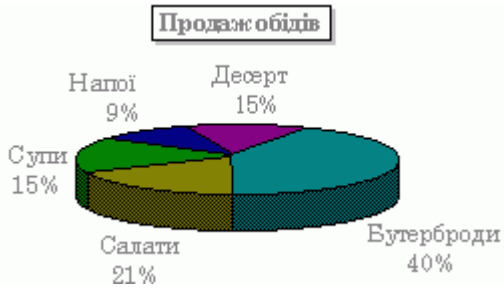

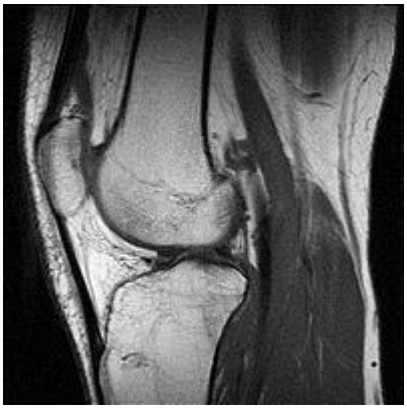

Кільцева діаграма Томографічне зображення коліна

Рис. 4.2. Приклади візуалізації даних (продовження)

Завдання

Провести візуалізацію даних згідно завдання приведеного в таблиці 4.1. Варіант завдання вибирають з таблиці 4.1 згідно з номером студента в журналі обліку.

Зміст звіту по лабораторній роботі:

Привести результати візуалізації у вигляді:

- Лінійної діаграми.
- Стовпчикова діаграми.
- Кругова діаграми

Графіка заданої функції. Інтервал побудови функції та крок табуляції необхідно вибрати так, щоб найкраще показати особливості поведінки заданої функції.

Таблиця 4.1

Вихідні дані для візуалізації

№ варіанту	Файл даних	Функція
1.	Візуалізація_technical_data_1.xlsx	$\frac{1}{x-2}$
2.	Візуалізація_medical_1.xlsx	$e^{(-\frac{1}{x})}$
3.	Візуалізація_economic_1.xlsx	$tg(x)$

4.	Візуалізація_it_data_1.xlsx	$ctg(x)$
5.	Візуалізація_technical_data_2.xlsx	$\frac{1}{x+1}$
6.	Візуалізація_medical_2.xlsx	$e^{(-\frac{1}{x+2})}$
7.	Візуалізація_economic_2.xlsx	$tg(x-2)$
8.	Візуалізація_it_data_2.xlsx	$ctg(x+2)$
9.	Візуалізація_it_data_10.xlsx	$\sin(x)e^{abs(x)}$
10.	Візуалізація_technical_data_3.xlsx	$\sin(x)e^{-abs(x)}$
11.	Візуалізація_medical_3.xlsx	$\cos(x)e^{abs(x)}$
12.	Візуалізація_economic_3.xlsx	$\cos(x)e^{-abs(x)}$
13.	Візуалізація_it_data_3.xlsx	$xe^{-abs(x)}$
14.	Візуалізація_technical_data_4.xlsx	$\sin(x)e^{abs(x)}$
15.	Візуалізація_medical_4.xlsx	$\sin(x)e^{-abs(x)}$
16.	Візуалізація_economic_4.xlsx	$x^2e^{-abs(x)}$
17.	Візуалізація_it_data_5.xlsx	$\frac{1}{x^2-1}$
18.	Візуалізація_technical_data_5.xlsx	$e^{(\frac{1}{x})}$
19.	Візуалізація_medical_5.xlsx	$tg(\frac{1}{x-1})$
20.	Візуалізація_economic_5.xlsx	$ctg(\frac{1}{x-1})$

21.	Візуалізація_it_data_5.xlsx	$\frac{1}{x^3+1}$
22.	Візуалізація_technical_data_6.xlsx	$e^{(-\frac{1}{x+2})}$
23.	Візуалізація_medical_6.xlsx	$tg(x^2-2)$
24.	Візуалізація_economic_6.xlsx	$ctg(\frac{x+2}{x-2})$
25.	Візуалізація_it_data_7.xlsx	$\sin^2(x)e^{abs(x)}$
26.	Візуалізація_technical_data_7.xlsx	$\sin^2(x)e^{-abs(x)}$
27.	Візуалізація_medical_7.xlsx	$\cos^2(x)e^{abs(x)}$
28.	Візуалізація_economic_7.xlsx	$\cos^2(x)e^{-abs(x)}$
29.	Візуалізація_it_data_8.xlsx	$\frac{1}{x^2-5}$
30.	Візуалізація_technical_data_8.xlsx	$e^{(\frac{1}{x}-4)}$
31.	Візуалізація_medical_8.xlsx	$tg(\frac{1}{x-4})$

32.	Візуалізація_economic_8.xlsx	$ctg(\frac{1}{x-3})$
33.	Візуалізація_it_data_9.xlsx	$\frac{1}{x^3+6}$

Література

1. Муляр В. П. М 90 Візуалізація даних та інфографіка. Харків: ФОП Панов А. М. 2020. 200 с.
2. Візуалізація даних. Від простого до складного. [Електронний ресурс]. – Режим доступу: https://www.tech.vernadskyjournals.in.ua/journals/2022/3_2022/10.pdf – Дата звернення: 02.10.2024.

Лабораторна робота № 5.
Визначення числових характеристик статистичного розподілу одновимірної послідовності випадкових величин

Короткі теоретичні відомості.

Математична статистика – розділ математики, в якому на основі дослідних даних вивчають імовірнісні закономірності масових явищ. Основними завданнями математичної статистики є статистична перевірка гіпотез, оцінювання розподілу статистичних ймовірностей та його параметрів, вивчення статистичної залежності, визначення основних числових характеристик випадкових вибірок, якими є: вибіркове середнє, вибіркові дисперсії, стандартне відхилення. Для вивчення статистичної залежності використовують методи теорії кореляції.

Вибірка – це множина об'єктів, подій, зразків або вимірів, за допомогою визначеної процедури вибраних зі статистичної популяції або генеральної сукупності для дослідження. Зазвичай обсяги генеральної сукупності дуже великі, що робить взяття до уваги усіх членів популяції непрактичним або неможливим. Вибірка становить множину або сукупність певного обсягу на основі аналізу яких визначають статистичні характеристики так, що в результаті можна зробити висновки або екстраполяцію із вибірки на всю генеральну сукупність.

Числові характеристики числового розподілу — це важливі показники для опису набору даних. Вони дозволяють зрозуміти середнє значення, розподіл, розсіювання даних та інші властивості вибірки. До основних характеристик належать:

1. **Середнє арифметичне** (mean) — середнє значення всіх елементів.
2. **Медіана** (median) — значення, яке ділить впорядкований набір даних на дві рівні частини.
3. **Мода** (mode) — значення, яке найчастіше зустрічається.
4. **Дисперсія** (variance) — міра розсіювання значень відносно середнього.
5. **Стандартне відхилення** (standard deviation) — квадратний корінь з дисперсії, також відображає розсіювання.

Розглянемо основні числові характеристики статистичного розподілу:

$\overline{x}_B = \frac{\sum_{i=1}^{n} x_i}{n}$ – вибіркове середнє, де x_i – варіанти, n – кількість вимірів (даних) у вибірці.

Якщо розглядати величини $x_1, x_2, \ldots x_n$ як незалежні і випадково розподілені величини, то $M(\overline{x}_B) = \overline{x}_Г$. Отже, у разі збільшення обсягу вибірки вибіркова середня за імовірністю прямує до генеральної середньої.

Вибірковою дисперсією D_B називають середнє арифметичне квадратів відхилень спостережних значень ознаки (вибіркової) сукупності від їх середнього значення $\overline{x}_B$:

$$, D_B = \frac{\sum_{i=1}^{n} (x_i - \overline{x}_B)^2}{n}, \text{ або } D_Г = \overline{x^2} - (\overline{x})^2.$$

Вибіркове середньоквадратичне відхилення (стандартне відхилення):

$$\sigma_B = \sqrt{D_B};$$

Вибіркова дисперсія («виправлена»): $s^2 = \frac{n}{n-1} D_B$.

Графічний аналіз рядів розподілу.

До графічних характеристик статистичних даних належать такі залежності:

- Емпірична функція розподілу – це функція, яка визначає для кожного значення x відносну частоту події: $F(x) = \frac{n_x}{n}$, де n_x –кількість варіант менших за x, n – загальна кількість варіант.
- Гістограма частот – це ступінчаста фігура, яка складається із прямокутників, основами яких є часткові інтервали, а їх висота дорівнює густині частоти: $\frac{n_i}{h}$, де n_i – кількість варіант i -

У процесі побудови емпіричних функцій розподілу та гістограм частот важливим є вибір кількості груп.

Кількість груп з однаковими інтервалами приблизно можна визначити за формулою американського вченого Стерджеса [4]:

$m = 1 + 3.334 * \log n$, де m – кількість інтервалів; n – обсяг сукупності.

Формула Стерджеса може бути використана за умови, що розподіл елементів сукупності за цією ознакою наближається до нормального закону розподілення.

Інтервали, тобто проміжок між крайніми значеннями ознаки в групі даних, бувають, одинакові, неоднакові, відкриті та закриті. Вибір виду інтервалу залежить від особливостей розподілу елементів сукупності.

Одинакові інтервали використовують у випадках, коли значення змінної (ознаки) x змінюються плавно, поступово, рівномірно. Ширину інтервалу h визначають за формулою:

$h = \frac{x_{\max} - x_{\min}}{m}$ де $x_{\max}$, $x_{\min}$ – найбільше та найменше значення ознаки (значення змінної) у сукупності.

Завдання:

1. Згенерувати одновимірну послідовність випадкових чисел що складається з 50000 значень і дослідити якість отриманої послідовності випадкових чисел із заданим значенням стандартного відхилення та середнього значення.
2. Побудувати графіки залежності похибок значень стандартного відхилення та середнього значення.
3. Побудувати функцію розподілу та стовпчикову діаграму для зарплат програмістів та тестувальників та визначити : середню зарплату, медіану зарплат, дисперсія зарплат, стандартне відхилення зарплат.

Вихідні дані до 3 пункту завдання приведені у розділі файли відповідної команди в Teams: Завдання_лаб_5. Номер файлу відповідає номеру студента в журналі обліку викладача.

Зміст звіту по лабораторній роботі:

1. Візуально представти згенеровані дані
2. Привести графіки залежності похибок значень стандартного відхилення та середнього значення та зробити висновки.
3. Побудувати функцію розподілу та стовпчикову діаграму для зарплат програмістів та тестувальників та провести аналіз отриманих даних та розраховані числові характеристики розподілу та зробити висновки.
4. В додатку необхідно привести вихідний код програми.

Література

1. Бахрушин В. Е. Математичне моделювання/В. Е. Бахрушин/ Навчальний посібник. – Запоріжжя: ГУ “ЗІДМУ”, 2004. - 140с.

Лабораторна робота № 6.
Кластеризація даних

Короткі теоретичні відомості.

Кластерний аналіз (англ. Data clustering) – задача розбиття заданої вибірки об'єктів (ситуацій) на підмножини, що називаються кластерами, так, щоб кожен кластер складався з схожих об'єктів, а об'єкти різних кластерів істотно відрізнялися [1–3].

Кластеризацію можна здійснювати двома основними способами: за допомогою ієрархічних чи ітераційних процедур.

Ієрархічні процедури – послідовні дії щодо формування кластерів різного рангу, підпорядкованих між собою за чітко встановленою ієрархією. Найчастіше ієрархічні

процедури здійснюються шляхом агломеративних (об'єднувальних) дій. Вони передбачають такі операції:

- Послідовне об'єднання подібних об'єктів з утворенням матриці подібності об'єктів;
- Побудова дендрограми (деревоподібної діаграми), яка відображає послідовне об'єднання об'єктів у кластери; формування із досліджуваної сукупності окремих кластерів на першому початковому етапі аналізу та об'єднання всіх об'єктів в одну велику групу на завершальному етапі аналізу.

Ітераційні процедури полягають в утворенні з первинних даних однорівневих (одного рангу) ієрархічно не підпорядкованих між собою кластерів.

До виконання пропонуються наступні ітераційні алгоритми кластеризації:

- Простий алгоритм кластеризації.
- K-середніх (K-means).

Вихідними засадами простого алгоритму кластеризації є такі положення:

Кожен з кластерів характеризується центром котрий є вектором $\vec{m}_k$ у багатовимірному просторі. Метод ґрунтується на мінімізації суми квадратів відстаней між кожним спостереженням та центром його кластера, тобто мінімізується функція:

$J = \sum_{j=1}^{p} \sum_{\vec{x} \in S_j} \| \vec{x} - \vec{m}_j \|$, де p – кількість кластерів, S_j - множина точок, що належить до j – того кластера, а $\vec{m}_j = \frac{1}{N_j} \sum_{\vec{x} \in S_j} \vec{x}$ вектор вибіркових середніх що визначає центр j - того кластера.

Евклідова відстань визначається наступним чином:

$$\| \vec{x} - \vec{m}_j \| = \sqrt{(\vec{x} - \vec{m}_j)^T (\vec{x} - \vec{m}_j)} = \sqrt{\vec{x}\vec{x}^T - 2(\vec{x}^T \vec{m}_J - \frac{1}{2} \vec{m}_J^T \vec{m}_J)}$$

Простий алгоритм кластеризації полягає в наступному:

- Задано N векторів $\{\vec{x}_1, \vec{x}_2, \ldots \vec{x}_N\}$.
- Центр першого кластера співпадає з довільним вектором, нехай $\vec{m}_1 = \vec{x}_1$.
- Задається порогова величина $T > 0$.
- Обчислюється відстань D_{21} між $\vec{m}_1$ та $\vec{x}_2$.
- Якщо $D_{21} > T$ то задається центр нового кластера $\vec{m}_2 = \vec{x}_2$ інакше $\vec{x}_2$ включається в кластер $\vec{m}_1$.
- Беремо наступну точку $\vec{x}_3$ і визначаємо відстань до обох кластерів D_{31}, D_{32}, якщо $D_{31}, D_{32} > T$ то утворюємо третій кластер, інакше включаємо вектор у кластер відстань до якого найменша.
- Продовжуємо процедуру для всіх решти точок.

Недоліки алгоритму полягають у залежності розбиття на кластери від:

- Вибору першої точки

- Порядку перебору векторів
- Від величини T

Переваги:

- Розбиття на кластери за один прохід.
- Непотрібно наперед задавати кількість кластерів.

Одним із найпоширеніших способів серед ітераційних процедур кластеризації є метод k-середніх розроблений у 1967 р. Дж. Мак-Куіном [1]. Застосування цього методу потребує здійснення таких кроків:

- Розділення вихідних даних досліджуваної сукупності на задану кількість кластерів;
- Обчислення багатовимірних середніх (центрів тяжіння) виділених кластерів;
- Розрахунку Евклідової відстані кожної одиниці сукупності до визначених центрів тяжіння кластерів та побудова матриці відстаней, яка ґрунтується на метриці відстаней. Використовують різні метрики відстаней, наприклад: Евклідова відстань (проста і зважена), Манхеттенська, Чебишева, Мінковського, Махалонобіса тощо.

Цей алгоритм має багато модифікацій, зокрема з використанням нечіткої логіки, наприклад, fuzzy c-means algorithm (FCM). Алгоритм нечітких к-середніх відомий ще під назвою ISODATA.

Один з простих варіантів методу K-середніх (K-means) можна представити наступним чином:

- Вибираємо p центрів кластерів, за звичай вибирають перші p векторів вибірки.
- На к – тій ітерації задана множина векторів вибірки розподіляється по кластерам за формулою: $\vec{x} \in S_J(k)$, якщо $\left\|\vec{x} - \vec{m}_J(k)\right\| < \left\|\vec{x} - \vec{m}_i(k)\right\|$ для всіх $i = 1, 2 \ldots p \ (i \neq j)$, $де\ S_J(k)$ – множина векторів, що входять у кластер з центром $\vec{m}_J$.
- Визначаємо нові центри кластерів: $\vec{m}_J(k) = \frac{1}{N_J} \sum_{\vec{x} \in S_J(k)} \vec{x}$, де N_j – число векторів що входять у множину $S_J(k)$
- Якщо $\vec{m}_J(k+1) = \vec{m}_J(k)$ то завершуємо, інакше повертаємось в п.2.

Завдання.

Реалізувати програму кластеризації даних класичним та метод К–середніх.

Вихідні набори векторів для кластеризації отримуємо з розділу файли команди Teams: Завдання_Лаб_6_ файл №.xlsx № відповідає номеру студента в журналі обліку ВИКЛАДАЧА. У випадку реалізації класичного алгоритму провести дослідження залежності результатів кластеризації від величини T.

У випадку алгоритму K- середніх необхідно провести дослідження ефективності алгоритму від початкового вибору центрів кластерів:

1. Вибрати перші p точок з файлу даних.
2. Вибрати останні p точок з файлу даних.
3. Випадковий вибір початкових центрів кластерів з вихідного масиву даних. Дослідження слід. провести десять разів. Проаналізувати отримані результати і зробити висновки

Зміст звіту по лабораторній роботі:

- Результати візуалізації вхідних даних
- Результати кластеризації класичним алгоритмом з візуалізацією результатів та привести характеристики отриманих кластерів при різних значеннях параметрів.
- Результати кластеризації методом К-середніх при різни способах вибору початкових значень центрів.

Результати необхідно надати у вигляді графіків на яких повинні бути зображено вектори кластерів розфарбовані різними кольорами в залежності від приналежності до певного кластера для обох методів кластеризації та для всіх значень параметра Т та способу вибору початкових значень центрів кластерів.

Зробити висновки з результатів дослідження.

Література:

1.Черняк О. І., Захарченко П. В. Інтелектуальний аналіз даних: Підручник. Київ, 2014.

2.Теорія економічного аналізу. [Електронний ресурс]. – Режим доступу: http://pidruchniki.com/11800912/ekonomika/klasterniy_analiz. – Дата звернення: 22.10.2024.

Лабораторна робота № 7.
Прогнозування часових послідовностей (наївні моделі прогнозу)

Короткі теоретичні відомості.

Прогнозування – це метод в якому використовується, як накопичений у минулому досвід, так і поточні припущення щодо майбутнього з метою його визначення. Прогнозування вважається одним з найскладнішим завдань АД. В різній літературі існує багато міфів байок щодо передбачення – від Нострадамуса до Ванги. В такий спосіб, людство протягом всієї історії намагалося вирішити це завдання. Вважається, що будь яка наука розвивається від описової до науки в повному розумінні цього слова, коли починає використовувати математичні методи і будувати математичні моделі досліджуваних процесів.

Отож, науковий підхід до розв’язання задачі прогнозування полягає у застосуванні певних математичних моделей, а не інтуїтивних прогнозів.

Як приклад можна навести спосіб використання математичних методів для прогнозування часового ряду. Будемо вважати, що поведінка якогось параметра складної системи (немає значення це технічний пристрій чи промислове виробництво) змінюється в часі t за гармонічним законом $u(t) = A\sin(\omega t + \varphi_0)$. Тоді достатньо трьох відомих (виміряних) значень величини $u(t_1),\ u(t_2),\ u(t_3)$ протягом періоду синусоїди для визначення параметрів A, ω, φ_0. Отже отримана функція буде зі стовідсотковою точністю передбачати поведінку системи в майбутньому.

Очевидно, що для реальних задач пошук адекватної математичної моделі є надскладним завданням. Тому на основі відомих даних (вимірів) намагаються створити найбільш адекватну до цього випадку математичну модель і, вважаючи її правильною, використати для прогнозування. В міру отримання нових даних модель уточнюється і отримуються нові прогнози.

Розглянемо найпростіші моделі прогнозу [1,2], де $\overline{y}_{n+1}$ – прогнозовані значення:

‘Завтра буде як сьогодні’

$$\overline{y}_{n+1} = y_n \qquad (7.1)$$

$$\overline{y}_{n+1} = y_n + (y_n - y_{n-1}) \qquad (7.2)$$

$$\overline{y}_{n+1} = y_n * \frac{y_n}{y_{n-1}} \qquad (7.3)$$

Просте середнє

$$\overline{y}_{n+1} = \frac{1}{n}(y_1 + y_2 + \ldots y_n) \qquad (7.4)$$

Ковзне середнє

$$\overline{y}_{n+1} = \frac{1}{k+1}(y_n + y_{n-1} + \ldots + y_{n-k}) \qquad (7.5)$$

Експоненціальне середнє, для $\alpha = [0 \div 1]$

$$\overline{y}_{n+1} = \alpha y_n + (1-\alpha)\overline{y}_n \qquad (7.6)$$

Для перевірки ефективності найпростіших моделей прогнозування вихідні дані беруться з офіційного сайту **Національного банку України (НБУ)**, а саме сторінки для перегляду графіків курсів валют [3]. Вибираються дані за один місяць. Вибір року, місяця та валюти – на вибір студента.

Завдання.

Реалізувати програму для прогнозування часових послідовностей заданими рекурентними співвідношеннями 7.2, 7.3, 7.4, 7.5. Також необхідно провести дослідження залежності якості прогнозування від величини α в методі заданого рекурентною формулою (7.6).

Вихідні дані та результати прогнозування необхідно подати у вигляді таких графіків:

- Вихідні дані та прогноз згідно співвідношень (7.1) – (7.4).
- Вихідні дані та прогноз згідно співвідношення (7.5) при різних значеннях вікна усереднення.
- Вихідні дані та прогноз згідно співвідношення (7.6) при різних значеннях α .

Для кодного з методів необхідно вивести статистику похибок:

- Максимальну похибку
- Мінімальну похибку
- Середню похибку
- Медіану похибки
- Моду похибки

- Стандартне відхилення похибки

Проаналізувати отримані дані та зробити висновки.

Література

1. Єріна А. М. Є 71 Статистичне моделювання та прогнозування: Навч. посіб- ник. — К. : КНЕУ, 2001. — 170 с. [Електронний ресурс]. – Режим доступу: http://www.gmdh.net/articles/theory/Stat Modeling.pdf. – Дата звернення: 14.04.2015.
2. Методи прогнозування. [Електронний ресурс]. – Режим доступу: http://wiki.taltek.info/Методи_прогнозування#. – Дата звернення: 14.04.2015.
3. Офіційний сайт **Національного банку України (НБУ)**, [Електронний ресурс]. – Режим доступу: https://bank.gov.ua/ua/markets/exchangerate-chart?cn%5B%5D=USD&startDate=1.01.2022&endDate=1.03.2024. – Дата звернення: 05.01.2025.
4. Галущак М. П., Галущак О. Я., Кужда Т. І. Прогнозування соціально-економічних процесів: навчальний посібник для економічних спеціальностей. – Тернопіль: ФОП Паляниця, 2021. – 160 с.

Лабораторна робота № 8.
Прогнозування часових послідовностей (Метод Хольта–Брауна)

Короткі теоретичні відомості.

Для прогнозування часових послідовностей в економіці та бізнесі використовують ряд методів, у яких присутні один чи декілька параметрів, які підбирають таким чином, щоб отримати найкращі результати прогнозування. Деколи ці методи називають адаптивними моделями прогнозування. Очевидно, що підібраний оптимальний набір даних для однієї задачі прогнозування не буде оптимальним для іншої задачі. Слід зауважити, що такого типу моделі прогнозування особливо ефективні для випадку коли прогнозовані послідовності мають періодичний характер як, наприклад, сезонні коливання цін на овочі чи фрукти.

Одним з таких методів є метод Хольта–Брауна. Метод Хольта–Брауна це просте експоненціальне згладжування з врахуванням тренду [1].

Алгоритм полягає в наступному:

1. Розрахунок експоненційно згладженого ряда:

$$L_n = \alpha y_n + (1-\alpha)(L_{n-1} - T_{n-1}),$$

де L_n – згладжена величина в точці,

α – коефіцієнт згладжування,

y_n – значення змінної ряду,

L_{n-1} – згладжена величина на попередньому кроці,

T_{n-1} – тренд на попередньому кроці.

Причому $L_1 = y_1$

2. Визначаємо значення тренда:

$$T_n = \beta(L_n - L_{n-1}) + (1-\beta)T_{n-1}$$

де T_n – значення тренду на даний момент,

β – коефіцієнт згладжування тренда,

L_n – експоненціально згладжена величина ряду в даний момент,

L_{n-1} – експоненціально згладжена величина ряду за попередній період,

T_{n-1} – значення тренда за попередні період.

Причому $T_1 = 0$

3. Робимо прогноз за методом Хольта:

$$\bar{Y}_{n+p} = L_n + pT_n$$

де $\bar{Y}_{n+p}$ – прогноз за методом Хольта,

L_n – експоненціально згладжена величина,

p – порядковий номер періоду прогнозування,

T_n – тренд за останній період.

Вихідні дані для прогнозування за один рік (на вибір студента) беруться з офіційного сайту **Національного банку України (НБУ)** [2].

Завдання.

Реалізувати програму для прогнозування часових послідовностей методом Хольта–Брауна.

Розділити дані на тренувальні та тестові. Першу половину даних використати для тренування, другу для тестування.

На основі тренувальних даних підібрати оптимальні значення параметрів. Оптимальними вважати параметри при яких середня похибка прогнозування мінімальна.

Статистику похибок для оптимальних значень α і β привести як при тренуванні так і тестуванні.

Результати привести у вигляді графіків.

Література.

1. Галущак М. П., Галущак О. Я., Кужда Т. І. Прогнозування соціально-економічних процесів: навчальний посібник для економічних спеціальностей. – Тернопіль: ФОП Паляниця, 2021. – 160 с.
2. Офіційний сайт **Національного банку України (НБУ)**, [Електронний ресурс]. – Режим доступу: https://bank.gov.ua/ua/markets/exchangerate-chart?cn%5B%5D=USD&startDate=1.01.2022&endDate=1.03.2024. – Дата звернення: 05.01.2025.

Лабораторна робота № 9.
Прогнозування часових послідовностей (лінійний та параболічний тренди)

Короткі теоретичні відомості.

У випадку прогнозування часових послідовностей з використанням лінійного та параболічного трендів часто велику роль відіграє візуалізація цих часових послідовностей.

Табличне представлення часового ряду й описових статистик частіше за все не дозволяє зрозуміти характер процесу, у той час як за графіком часового ряду можна зробити досить багато висновків. Надалі вони можуть бути перевірені й уточнені за допомогою розрахунків.

Людське око досить упевнено визначає за графіком часового ряду:

- Наявність тренду і його характер.
- Наявність сезонних і циклічних компонент.

Графічний аналіз ряду звичайно задає напрямок його подальшого аналізу.

Як і більшість інших видів аналізу, аналіз часових рядів передбачає, що дані містять систематичну складову (зазвичай включає кілька компонент) і випадковий шум (помилку), який ускладнює виявлення регулярних компонент. Більшість методів дослідження часових рядів включає різні способи фільтрації шуму, що дозволяють побачити регулярну складову більш чітко.

Саме таким чином працює метод виявлення тренду з використанням методу найменших квадратів [1].

Розглянемо найпростіший випадок – лінійний тренд.

Рівняння прямої лінії тренда має вигляд:

$$y_i = a + bt_i$$

де y_i рівень тренда для періоду або моменту з номером t_i

a – вільний член рівняння, рівний середньому рівню тренду для періоду (моменту) з нульовим номером;

b – головний параметр лінійного тренду – середня абсолютна зміна за прийняту в ряді одиницю часу.

Величина параметрів a і b визначається за методом найменших квадратів як показано у лабораторній роботі № 3.

Параболічний тренд.

Рівняння параболічного тренда (тренда другого порядку):

$$y_i = a + bt_i + ct_i^2$$

Як і в попередньому випадку величини параметрів a, b, c визначаються за методом найменших квадратів. Очевидно, що при більш складних залежностях можна спробувати для апроксимації часового ряду поліноми ще вищого порядку.

Вихідні дані для прогнозування за один рік (на вибір студента) беруться з офіційного сайту **Національного банку України (НБУ)** [2].

Завдання

Реалізувати програму для прогнозування заданих часових послідовностей.

Розділити дані на тренувальні та тестові. Першу половину даних використати для тренування, другу для тестування.

На основі тренувальних даних необхідно знайти параметри рівняння лінійного та параболічного тренду і вибрати кращий випадок. Привести значення коефіцієнтів вибраного рівняння тренду.

Окрім того, вихідні дані та результати прогнозу представити у вигляді графіків на яких зобразити вихідні дані та результати прогнозування з використанням лінійного та параболічного тренду.

Література

1. Єріна А. М. Є 71 Статистичне моделювання та прогнозування: Навч. посібник. – К. : КНЕУ, 2001. — 170 с. [Електронний ресурс]. – Режим доступу: http://www.gmdh.net/articles/theory/Stat Modeling.pdf. – Дата звернення: 14.04.2015.
2. Офіційний сайт **Національного банку України (НБУ)**, [Електронний ресурс]. – Режим доступу: https://bank.gov.ua/ua/markets/exchangerate-chart?cn%5B%5D=USD&startDate=1.01.2022&endDate=1.03.2024. – Дата звернення: 05.01.2025.

Лабораторна робота № 10.
Методи одно та багатовимірної оптимізації

Короткі теоретичні відомості.

Пошук оптимального значення якоїсь величини, класу функцій чи оптимального параметра може бути проміжною чи завершальною стадією АД. Ця задача зводиться до задачі одновимірної чи багатовимірної оптимізації. Розглянемо найпростіші методи одно та багатовимірної оптимізації [1,2].

Задача одновимірної оптимізації полягає у відшуканні мінімуму (або максимуму) функції $y = f(x)$ на відрізку [a, b].

Ця задача має самостійне значення і водночас її доводиться розв'язувати при оптимізації функцій багатьох змінних.

Відразу треба зауважити, що класичний підхід до розв'язування задач одновимірної оптимізації, що ґрунтується на відшуканні коренів рівняння, $f'(x) = 0$ далеко не завжди може бути реалізований на практиці.

По-перше, в практичних задачах оптимізації часто взагалі невідомо, чи є функція $y = f(x)$ диференційованою, наприклад, якщо вона задана таблицею.

По-друге, задача розв'язування рівняння $f'(x) = 0$ з обчислювальної точки зору має такий же порядок складності, як і вихідна задача. Ось чому є потреба в застосуванні методів оптимізації, відмінних від класичних, тобто таких, які не зв'язані з похідною.

Розглянемо деякі з таких методів одновимірної оптимізації стосовно, так званих, унімодальних функцій.

Стратегія пошуку мінімуму функції полягає у пошуку такого інтервалу $[a_n; b_n]$, який містить значення x^* при якому функція $y = f(x)$ приймає мінімальне значення і довжина якого менша заданого значення δ .

Найпростішим методом є метод половинного ділення (дихотомії) алгоритм якого показаний на рисунку 10.1. Де [a, b] – інтервал пошуку, δ – точність, $eps < 0.5\delta$. Даний метод працездатний лише для випадку унімодальної функції $f(x)$ Іншими словами, тоді коли на інтервалі $[a, b]$ має місце лише одне мінімальне значення функції (єдиний екстремум функції $f(x)$). Крім того даний метод використовується лише для пошук екстремумів одновимірної функції.

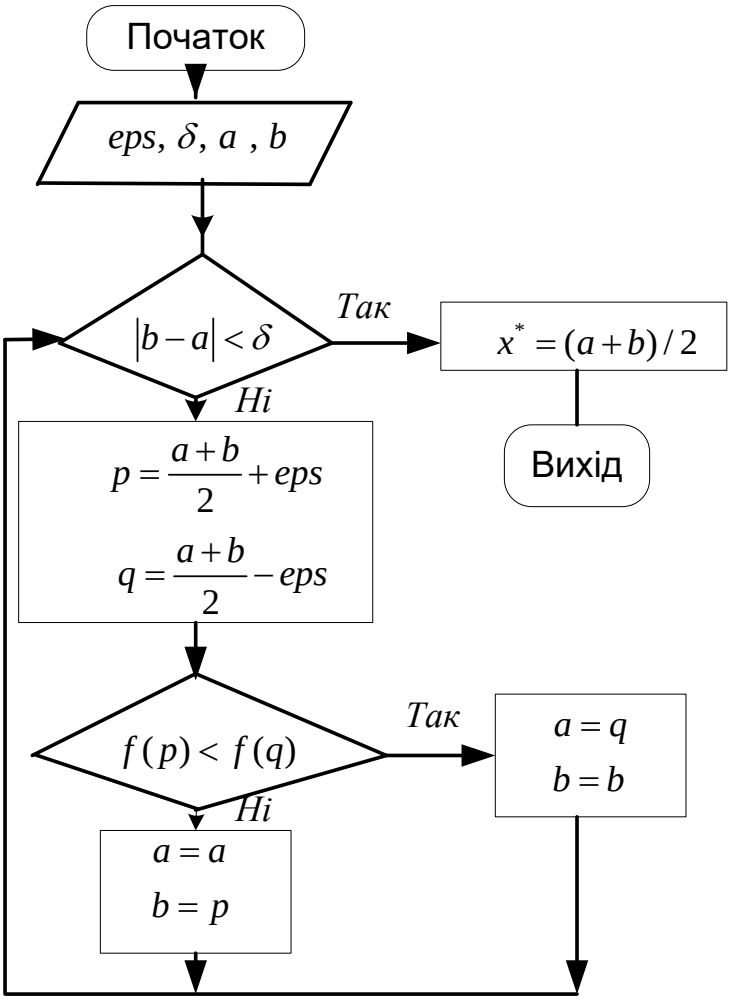

Рис 10.1. Алгоритм дихотомічного пошуку

При розв'язуванні задачі максимізації функції $f(x)$ необхідно замінити її на функцію – $f(x)$.

Наступний простий метод пошуку екстремуму функції є метод випадкового пошуку.

Метод випадкового пошуку (МВП) застосовується для знаходження мінімуму (максимуму) функції $y = f(x)$ яка задана в будь-якій допустимій області D. Функція може мати довільну кількість екстремумів в області D і бути багатовимірною.

Розглянемо реалізацію даного методу для функції однієї змінної. Нехай довільна функція $f(x)$ задана на проміжку $[a,b]$. За допомогою генератора випадкових чисел, отримуємо послідовність рівномірно розподілених на проміжку [0,1] чисел x_i. Обчислюємо та порівнюємо між собою значення функції $f(x)$ в точках x_i. Мінімальне з них приймається за оцінку мінімуму функції $f(x)$ на проміжку [a, b].

Якщо N прямує до нескінченності, отримана оцінка по ймовірності збігається до глобального мінімуму функції, що розглядається.

Найбільш універсальними і швидкозбіжними є градієнтні методи одно та багатовимірної оптимізації.

У багатовимірному випадку нам необхідно знайти мінімум функції $f(\vec{x})$ де $\vec{x} = (x_1, x_2, \ldots x_n)$.

Для мінімізації по методу градієнтного спуску вибирається початкова точка $\vec{x}^0 = (x^0{}_1, x^0{}_2, \ldots x^0{}_n)$. Функція $f(\vec{x}) = f(\vec{x}^0)$ визначає в n вимірному просторі гіперповерхню, градієнт якої визначає напрямок найшвидшого зростання функції. Тому напрямок $-gradf(\vec{x})$ визначає найшвидше зменшення функції. Спуск по цьому напрямку визначає нове наближення $\vec{x}^1$.

Шуканий вектор $\vec{x}^1$ на k – тому кроці ітераційного методу визначається так:

$$\vec{x}^{k+1} = \vec{x}^k - h * gradf(\vec{x}^k), \text{ де } \vec{x}^k = (x_1^k, x_2^k, \ldots x_n^k),$$

$$gradf(\vec{x}^k) = \left(\frac{\partial f(\vec{x}^k)}{\partial x_1}, \ldots, \frac{\partial f(\vec{x}^k)}{\partial x_n}\right)$$

Критерієм закінчення ітераційного процесу можуть слугувати умови виконання нерівностей: $\left| f(\vec{x}^{k+1}) - f(\vec{x}^k) \right| < \varepsilon$ або $\max_i \left| \frac{\partial f(\vec{x}^k)}{\partial x_i} \right| < \varepsilon$.

Адаптивний алгоритм пошуку показаний на рисунку 10.2. Адаптивність алгоритму полякає у зміні значення коефіцієнта h що визначає швидкість наближення до екстремуму функції.

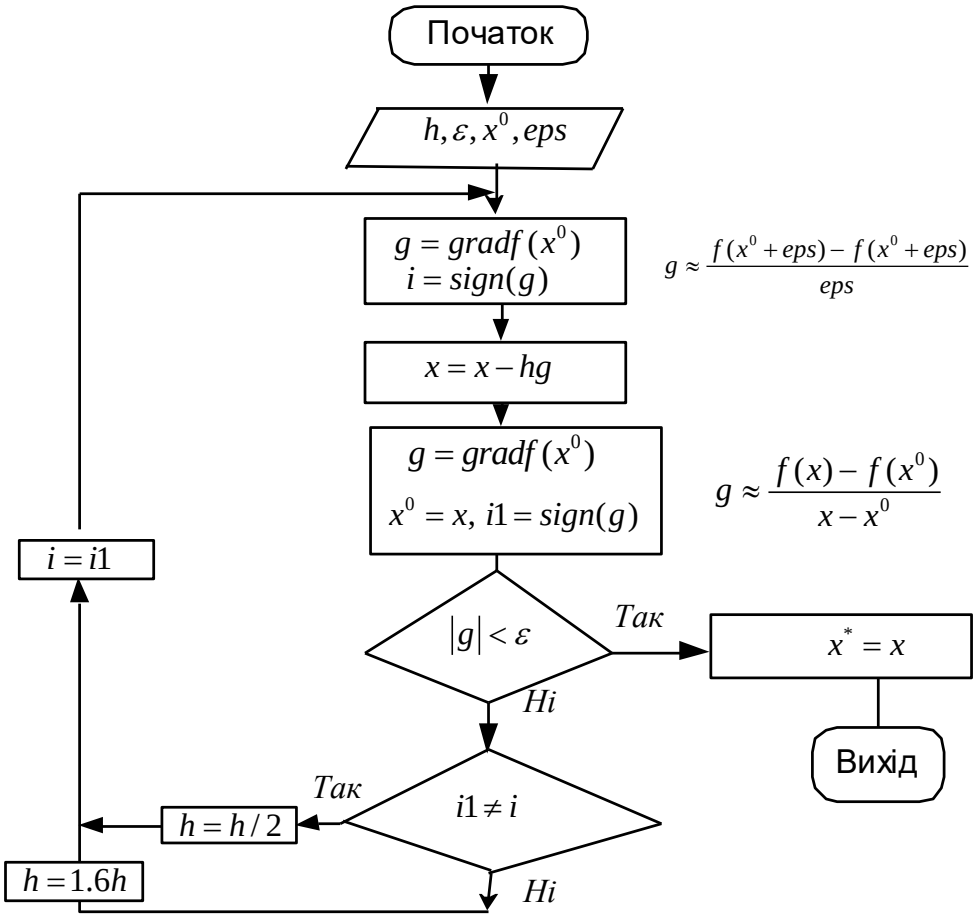

Рис. 10.2. Алгоритм найшвидшого спуску для одновимірної функції

Очевидно що даний метод гарантує лише знаходження локального екстремуму функції $f(x)$.

Таблиця 10.1

Варіанти одновимірних функцій

№ п.п	Функція	Інтервал
1.	$f(x)=\exp(x)+x^2$	[-1;0]
2.	$f(x)=\exp(x)+\frac{1}{x}$	[0.5;1]
3.	$f(x)=\exp(x)-\ln(x)$	[0.3;1]
4.	$f(x)=\exp(x)+\frac{1}{x+1}$	[-0.5;0.5]
5.	$f(x)=tg(x)+\frac{1}{x}$	[0.5;1]
6.	$f(x)=tg(x)+\exp(-x)+x$	[-1;0]
7.	$f(x)=x^2+\sin(x)$	[-1;0]
8.	$f(x)=\exp(x)-\sin(x)$	[0;1]
9.	$f(x)=x^4+2x^2+4x$	[-1;0]
10.	$f(x)=x*\exp(x)+x^2$	[-1;0]
11.	$f(x)=\frac{x+2}{x^2}-x$	[-1;-0.5]
12.	$f(x)=x+\frac{1}{\ln(x)}$	[1.5;2.5]
13.	$f(x)=x+\ln^2(x)$	[0.3;1]
14.	$f(x)=x-\ln(\ln(x))$	[1.3;2.3]
15.	$f(x)=x+\frac{1}{arctg(x)}$	[0.5;1.5]
16.	$f(x)=\exp(-x)-\frac{1}{x}$	[-1;-0.5]
17.	$f(x)=\exp(-x)+x^2$	[0;1]
18.	$f(x)=\exp(\frac{1}{x})+\ln(x)$	[1;3]
19.	$f(x)=\exp(-x)+\frac{1}{1-x}$	[-0.5;0.5]
20.	$f(x)=-tg(x)-\frac{1}{x}$	[-1;0.5]
21.	$f(x)=\exp(x)-tg(x)-x$	[0,1]
22.	$f(x)=x^2-\sin(x)$	[0;1]
23.	$f(x)=\exp(-x)+\sin(x)$	[-1;0]
24.	$f(x)=x^4+2x^2-4x$	[0;1]

25.	$f(x) = x^2 - x * \exp(-x)$	[0;1]
26.	$f(x) = x + \frac{2-x}{x^2}$	[0.5;1]
27.	$f(x) = \frac{1}{x} - \frac{1}{\ln(x)}$	[0.3;0.7]
28.	$f(x) = \frac{1}{x} + \ln^2(x)$	[1;3]
29.	$f(x) = \exp(\frac{1}{x}) + \ln(x)$	[1;3]
30.	$f(x) = \exp(x-1) + \frac{1}{x}$	[0.5;1.5]
31.	$f(x) = \exp(\frac{1}{x}) + \ln(x)$	[0.95;3.1]
32.	$f(x) = x * \exp(x) + x^2$	[-1.5;0.2]

Таблиця 10.2.

Варіанти двохвимірних функцій

N п.п	Функція
1	$f(x,y) = ((x+y-c1)^2 + (x-y+c2)^2) - 2(xy + c1c2)$
2	$f(x,y) = c1 * ((x-y+c2)^2) + c2 * ((x+y-c1)^2) - (x^2 + y^2)$
3	$f(x,y) = -e^{-((x+c1)^2+(y-c2)^2)} + ((x+y)^2 - c1 * c2)$
4	$f(x,y) = -ln(((x+c1)^2 + (y-c2)^2)^2 + c1^2 - c2^2)$
5	$f(x,y) = ((x+c1)^2 + (y-c2)^2)^2 + 0.1 * (x^2 - y^2) - c1 * c2$
6	$f(x,y) = sqrt(((x-c1)^2 + (y+c2)^2)^2 + c1 * x - c2 * y)$
7	$f(x,y) = cosh((x-c1)^2 + (y-c2)^2) - sinh(x * y - c1 * c2)$
8	$f(x,y) = sin(((x-c1)^2 + (y+c2)^2)^2 + c1 * x - c2 * y)$
9	$f(x,y) = ((x+y-c1)^2 + (x-y+c2)^2) - 2(xy + c1c2)$
10	$f(x,y) = c1 * ((x-y+c2)^2) + c2 * ((x+y-c1)^2) - (x^2 + y^2)$
11	$f(x,y) = -e^{-((x+c1)^2+(y-c2)^2)} + ((x+y)^2 - c1 * c2)$
12	$f(x,y) = -ln(((x+c1)^2 + (y-c2)^2)^2 + c1^2 - c2^2)$
13	$f(x,y) = ((x+c1)^2 + (y-c2)^2)^2 + 0.1 * (x^2 - y^2) - c1 * c2$
14	$f(x,y) = sqrt(((x-c1)^2 + (y+c2)^2)^2 + c1 * x - c2 * y)$
15	$f(x,y) = cosh((x-c1)^2 + (y-c2)^2) - sinh(x * y - c1 * c2)$
16	$f(x,y) = sin(((x-c1)^2 + (y+c2)^2)^2 + c1 * x - c2 * y)$
17	$f(x,y) = ((x+c1)^2 + (y-c2)^2)^2 + 0.1 * (x^2 - y^2) - c1 * c2$
18	$f(x,y) = ((x+y-c1)^2 + (x-y+c2)^2) - 2(xy + c1c2)$
19	$f(x,y) = c1 * ((x-y+c2)^2) + c2 * ((x+y-c1)^2) - (x^2 + y^2)$
20	$f(x,y) = -e^{-((x+c1)^2+(y-c2)^2)} + ((x+y)^2 - c1 * c2)$
21	$f(x,y) = -ln(((x+c1)^2 + (y-c2)^2)^2 + c1^2 - c2^2)$
22	$f(x,y) = ((x+c1)^2 + (y-c2)^2)^2 + 0.1 * (x^2 - y^2) - c1 * c2$
23	$f(x,y) = sqrt(((x-c1)^2 + (y+c2)^2)^2 + c1 * x - c2 * y)$
24	$f(x,y) = cosh((x-c1)^2 + (y-c2)^2) - sinh(x * y - c1 * c2)$
25	$f(x,y) = sin(((x-c1)^2 + (y+c2)^2)^2 + c1 * x - c2 * y)$

26	$f(x,y) = ((x+c1)^2 + (y-c2)^2)^2 + 0.1 * (x^2 - y^2) - c1 * c2$
27	$f(x,y) = ((x+y-c1)^2 + (x-y+c2)^2) - 2(xy + c1c2)$
28	$f(x,y) = c1 * ((x-y+c2)^2) + c2 * ((x+y-c1)^2) - (x^2 + y^2)$
29	$f(x,y) = -e^{-((x+c1)^2+(y-c2)^2)} + ((x+y)^2 - c1 * c2)$
30	$f(x,y) = -ln(((x+c1)^2 + (y-c2)^2)^2 + c1^2 - c2^2)$

Завдання

Необхідно реалізувати всі методи знаходження екстремуму функції наведені в теоретичній частині даної лабораторної роботи для одновимірних функцій.

Функція $f(x)$ відповідає номеру студента в журналі обліку і вибирається з таблиці 10.1 та 10.2.

В програмі необхідно передбачити перевірку правильності отриманого результату. Окрім того, необхідно провести візуалізацію отриманого результату котра полягає у наступному: необхідно графічно зобразити задану функцію в околі знайденого екстремуму і виділити точку знайденого екстремуму. В програмі слід передбачити можливість оперативної зміни околу пошуку екстремуму функції, та величин що визначають точність знаходження екстремуму функції.

Література

1. Бейко І.В., Зінько П.М., Наконечний О.Г. Задачі, методи і алгоритми оптимізації: Навчальний посібник.-Рівне:НУВГП,2011.-624с.
2. Хвищун І. О. Програмування і математичне моделювання/ І. О. Хвищун / Підручник. – Л: Видавничий Дім «Ін Юре», 2007. – 544 с.: іл.

Лабораторна робота №11.

Вирішення задачі класифікації за допомогою однонейронної мережі.

Короткі теоретичні відомості . Одним з ефективних напрямків вирішення задачі класифікації є використання нейромереж з пошаровою структурою. Нейромережа складається з окремих нейронів пов'язаних між собою за допомогою так званих синаптичних зв'язків. Математична модель нейрона схематично показана на рисунку 11.1.

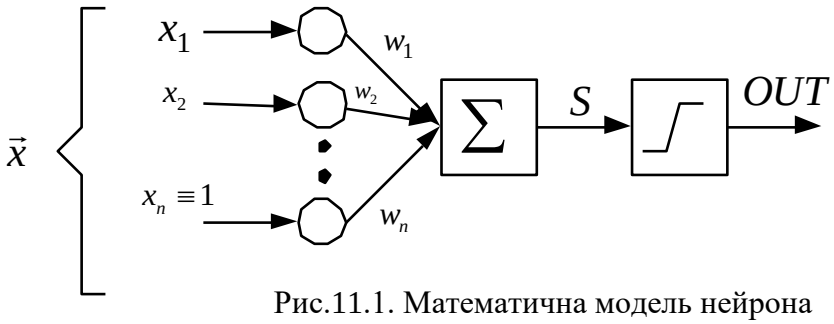

Рис.11.1. Математична модель нейрона

На вхід мережі подається вхідний сигнал $\vec{x}$ який є вектором з компонентами заданими дійсними числами. N - та компонента вхідного вектора тотожно дорівнює одиниці і відповідає за зміщення функції активації на величину ω_n. Після суматора отримуємо:

$$S = \sum_{j=1}^{n} w_j x_j$$

Далі зважена сума S подається на функцію активації. В більшості нейромереж використовується сигмоїдальна функція активації:

$$OUT = \frac{1}{1+\exp(-\alpha S)}$$

Константа α визначає крутизну функції активації. При зменшенні α сигмоїд стає більш пологим і в границі при $\alpha \to 0$ вироджується в горизонтальну лінію на рівні 0.5. При збільшенні α сигмоїдальна функція наближається до функції одиничного скачка (функції Хевісайда) з порогом в точці $\theta = x_n\omega_n = \omega_n$. Вигляд функції показаний на рисунку 11.2. Очевидно, що значення функції змінюється в межах від нуля до одиниці при зміні аргументу від $-\infty$ до $+\infty$, тому говорять, що вона має стискаючу властивість. Цінною властивістю функції є простий вираз для знаходження її похідної та її неперервність: $f'(S) = \alpha f(S)(1 - f(S))$.

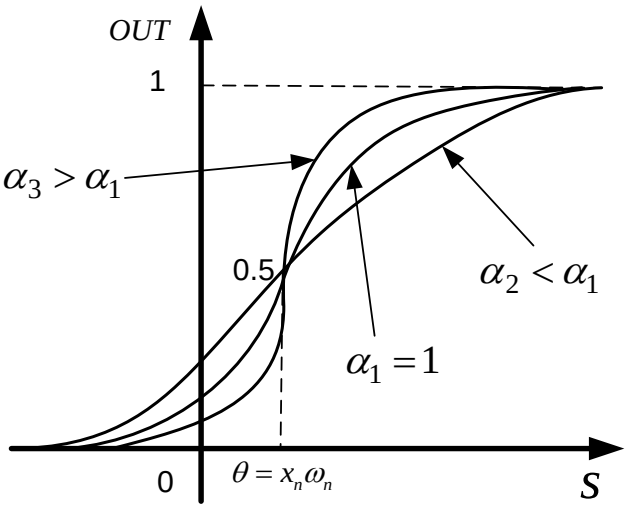

Рис. 11.2. Вигляд сигмоїдальної функції при різних значеннях α

Розглянемо яким чином вирішується задача класифікації за допомогою нейромереж на прикладі найпростішої задачі – розподіл множини вхідних даних на два класи.

З точки зору класифікації нейромереж по типу навчання, задача класифікації відноситься до навчання з вчителем. А для такого типу навчання нам необхідно мати навчаючі пари векторів.

На рисунку 11.3 показано множину вхідних даних що представляють собою двохвимірні вектори. Вхідна множина складається з двох множин А та В. Необхідно таким чином підібрати значення ваг нейрона (рис. 2.1) щоб значення виходу мережі out було різним для векторів з множин А та В

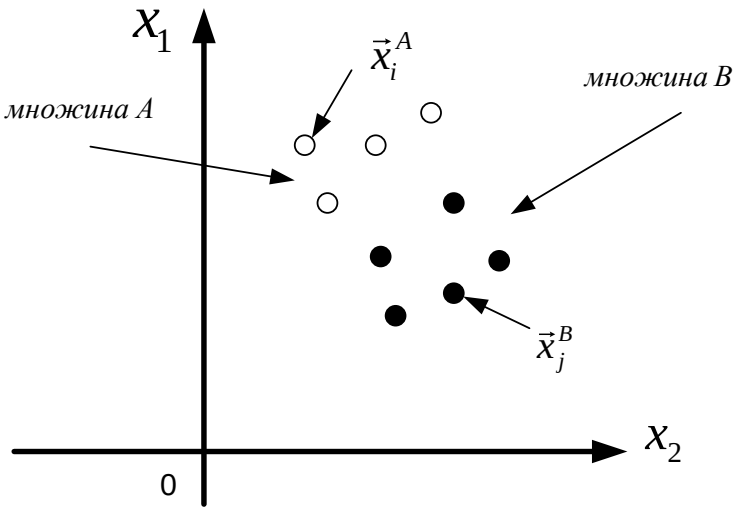

Рис. 11.3. Вхідна множина для класифікації

Наприклад, для всіх векторів з множини А значення виходу нейрона повинно дорівнювати одиниці (бути близьким до одиниці) а для всіх векторів з множини В дорівнювати нулю (бути близьким до нуля) або навпаки. Якщо відомо значення вектора і його приналежність до відповідної множини можна утворити навчаючі пари векторів для множини А: $\{\vec{x}_i^A, T^A\}$, де $T^A = 1$, а для множини В: $\{\vec{x}_i^B, T^B\}$, де $T^A = 0$. Очевидно, що у випадку сигмоїдальної функції активації бажані значення виходу можна досягти лише з певною точністю. Таким чином на сукупності векторів належність яких до певної множини відома ми можемо провести навчання мережі а потім уже навчену мережу використати для класифікації векторів приналежність яких до певної множини невідома.

Задача навчання мережі відноситься до задачі оптимізації. Найбільш загальним способом оптимізації нейромережі є ітераційна (поступова) процедура підбору ваг, котру називають навчанням. Для нашої задачі навчанням з вчителем, бо воно проходить за допомогою навчальної вибірки прикладів $\{x^i, T^i\}$ де T^i бажаний вихід при вхідному векторі x^i.

Якщо задати функціонал похибки мережі, то задача навчання зводиться до його мінімізації. За звичай, в якості функціоналу похибки вибирають величину:

$E = \frac{1}{2}(out - T)^2$ (10.1), де out вихід мережі, T - бажаний вихід мережі. Для мінімізації функціонала похибки (10.1) використовують градієнтні методи оптимізації.

Наприклад, можна запропонувати наступну ітераційну процедуру підбору ваг (метод найшвидшого спуску): $\vec{w}^{k+1} = \vec{w}^k - \eta \frac{\partial E}{\partial \vec{w}^k}$

або $$w_i^{k+1} = w_i^k - \eta \frac{\partial E}{\partial w_i^k}.$$

Величину η називають швидкістю навчання на кроці k. Можна показати, що поступово зменшуючи темп навчання, наприклад за законом $\eta = \frac{1}{k}$, описана вище процедура приводить до локального мінімуму. Ітераційна процедура продовжується до тих пір поки значення функціоналу похибки для кожної навчаючої пари менший заданої величини E_0.

Для мережі показаної на рисунку 10.1 при $N = 3$ та функціоналом похибки заданим формулою(10.1) величини корекції ваг можна записати наступним чином:

$$\frac{\partial E}{\partial w_1^k} = (out^k - T^i) out^k (1 - out) x_1^k = \delta x_1^k$$

$$\frac{\partial E}{\partial w_2^k} = (out^k - T^i) out^k (1 - out) x_2^k = \delta x_2^k$$

$$\frac{\partial E}{\partial w_3^k} = (out^k - T^i) out^k (1 - out) x_3^k = \delta .$$

Для вирішення більш складних задач класифікації використовуються трьохшарові нейронні мережі з великою кількістю нейронів.

Окрім того можуть використовуватися інші функції активаці.

Вигляд кусково-лінійної функції активації показаний на рисунку 11.3.

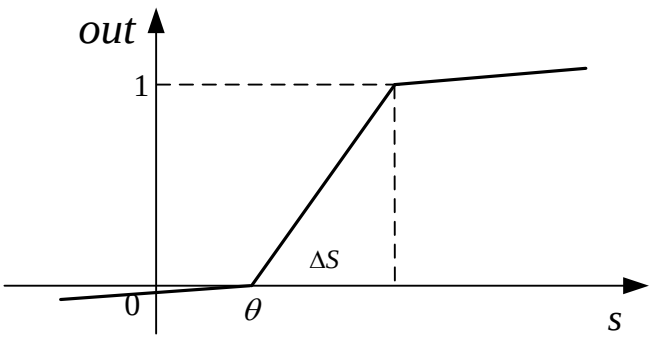

Рис. 11.3. Кусково-лінійна функція активації

Вигляд функції активації $th(s)$ показаний на рисунку 3.2.

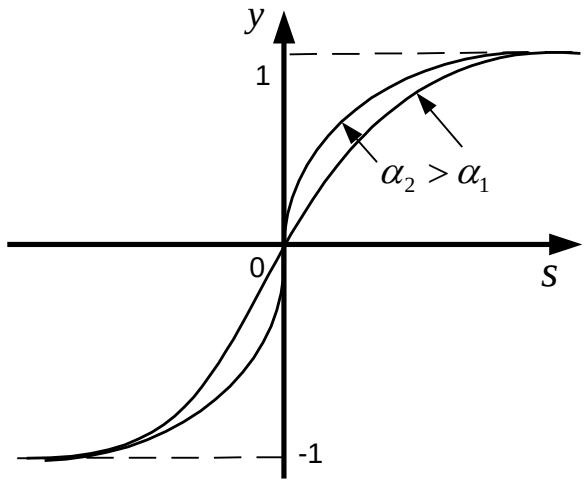

Рис. 11.4. Функція активації $y = th(s) = \dfrac{\exp(\alpha s) - \exp(-\alpha s)}{\exp(\alpha s) + \exp(-\alpha s)}$.

Похідна функції: $th(s)' = \alpha(1 - th^2(\alpha s))$.

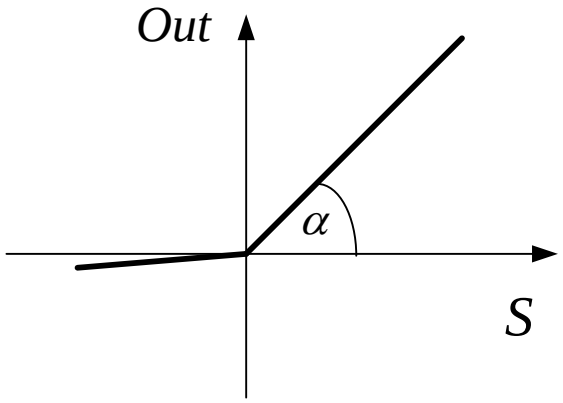

Рис.11.5. Функція активації ReLu.

Вихідний сигнал визначається залежністями:

$$Out = 0,\ S < \theta$$

$$Out = S,\ S > \theta$$

Завдання

За допомогою одно нейронної мережі реалізувати класифікатор вхідного потоку даних (двохвимірних векторів) для трьох функцій активації (сигмоїдальна, *Th*, *ReLu*) на два класи котрі задані фіксованим набором векторів. Вихідні набори векторів для навчання нейромережі отримуємо з розділу файли команди Teams: Завдання_Дані_лаб11 файл №.xlsx № відповідає номеру студента в журналі обліку ВИКЛАДАЧА.

Масив навчаючих пар необхідно розділити на частини:

- Для навчання нейромережі.
- Для валідації (при необхідності)
- Для тестування.

Перед початком навчання, за звичай, потрібно попередню підготовку даних.

Вимоги до програми:

- Реалізована програма повинна дозволяти проводити навчання при довільних заданих параметрів - α , η , E_0 (задана точність навчання)
- Виводити кількість епох навчання при заданих параметрах.
- Для перевірки результату навчання передбачити ввід довільних вхідних даних на навчену мережу та отримання прогнозованого вихідного значення.

Зміст звіту по лабораторній роботі:

- привести графік залежності $S = \vec{x}\vec{w} = x_1 w_1 + x_2 w_2 + w_3 = 0$ та значень навчаючих пар в координатах (x_1, x_2) для навченої нейромережі.
- Передбачити вікно для вводу координат тестових точок для перевірки правильного функціонування навченої мережі.
- Візуалізувати здатність навченої нейромережі проводити класифікацію довільних вхідних даних в залежності від заданої точності навчання при різних значеннях точності навчання.
- У привести результати роботи програми для всіх пунктів завдання до роботи при різних функціях активації.
- Зробити висновки щодо вибору оптимальних значень параметрів при реалізації нейромережі.
- У додатку привести текст написаної програми із поясненнями про призначення змінних та структури програми (блок генерації навчаючих, блок навчання персептрона, блок перевірки якості навчання);

Література

1. Любунь З. М. Основи теорії нейромереж / З. М. Любунь /: Текст лекцій. – Львів: Видавничий центр ЛНУ імені Івана Франка, 2007. –142 с.
2. Любунь З. М. Інтелектуальний аналіз даних. / З. М. Любунь, В. Г. Рабик , І. Д. Карбовник /: Методичні вказівки до виконання лабораторних робіт для студентів за напрямом підготовки 6.050101 “Комп’ютерні науки”– Львів: Видавничий центр ЛНУ імені Івана Франка, 2015. –70 с.
3. Добровська Л. М. Теорія та практика нейронних мереж : навч. посіб. / Л. М. Добровська, І. А. Добровська. – К. : НТУУ «КПІ» Вид-во «Політехніка», 2015. – 396 с.

Лабораторна робота №12.
Вирішення задачі кластеризації за допомогою нейронної мережі

Короткі теоретичні відомості.

Одним з ефективних напрямків вирішення задачі як класифікації так і кластеризації даних є використання нейромереж [1,2].

На відміну від задач класифікації ми не маємо жодної інформації а ні про кількість кластерів, а ні про область їх розташування. Тому не можемо сформувати навчаючі пари і відповідно звести задачу до мінімізації функціонала похибки. У даному випадку мережа “змушена” навчатися на самій вхідній множині даних. При відсутності зовнішньої мети “вчителем” мережі можуть бути лише самі дані, а саме закономірності, котрі відрізняють їх від шуму. Такий тип навчання називається навчанням без “вчителя”.

Для багатьох задач кластеризації даних використовуються одношарові нейронні мережі що складаються з нейронів-індикаторів. Математична модель нейрона-індикатора показана на рисунку 12.1.

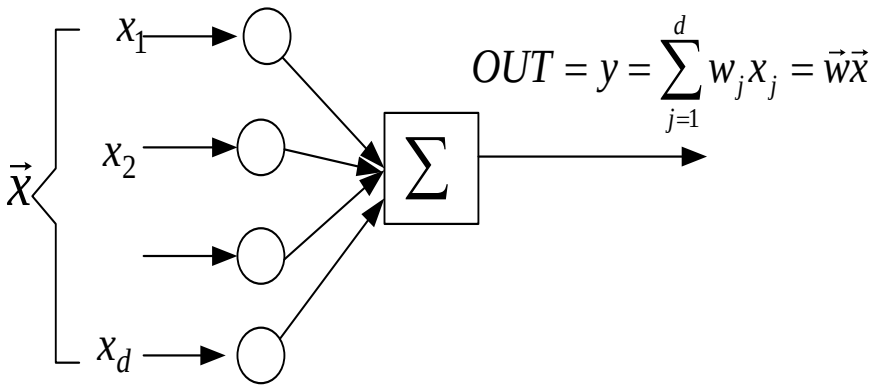

Рис.12.1. Математична модель нейрона-індикатора

Після відповідного навчання нейрона (корекції ваг за набором прикладів $\{\vec{x}^n\}$) амплітуда його виходу може бути індикатором того, наскільки даний вхідний вектор відповідає навчаючому набору. Іншими словами, нейрон може стати індикатором приналежності вхідної інформації до заданої групи прикладів.

Правило навчання окремого нейрона-індикатора є локальним, оскільки базується тільки на інформації безпосередньо доступній самому нейрону – значеннях його входів і виходів.

Правило навчання мережі з обмеженням величини росту ваг дістало назву правилонавчання Ойа. Значення величин корекції ваг при подачі на вхід нейрона i – тового вектора $\vec{x}_i$ визначаються рівнянням у векторній формі $\Delta\vec{\omega} = \eta y_i(\vec{x}_i - y_i\vec{\omega})$. Таке правило максимізує чутливість виходу нейрона при обмеженій амплітуді ваг.

Розглянемо приклад мережі, котра проводить кластеризацію двовимірних вхідних векторів на два кластери. Структура такої мережі показана на рисунку 12.2.

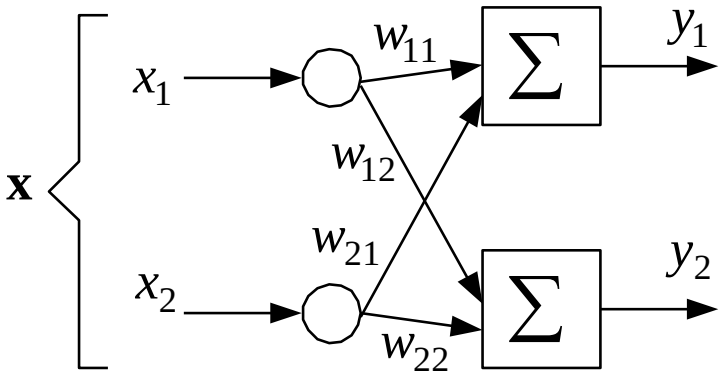

Рис.12.2. Структура двонейронної мережі для кластеризації даних

Значення виходів мережі y_i визначаються залежностями:

$$y_1 = w_{11}x_1 + w_{21}x_2$$
$$y_2 = w_{12}x_1 + w_{22}x_2 .$$

Або у векторній формі:

$$\vec{y} = W\vec{x}$$

Зазвичай, вхідні вектори нормуються: $|\vec{x}| = 1$. Нормування вхідного вектора можна провести шляхом перерахунку його компонент: $x_j = \dfrac{x_j}{\sqrt{\sum_{i=1}^{d} x_i^2}}$, де d розмірність вхідних даних (для нашого прикладу $d = 2$). Допустимо, що множина вхідних векторів є сукупністю двох множин c_1 та c_2, вектори у яких розподілені , наприклад, згідно закону Гауса (або по іншому закону). Графічно це зображено на рисунку 12.3, там же показано початкові положення векторів ваг нейронів $\vec{w}_1$, $\vec{w}_2$ положення яких вибирається випадково.

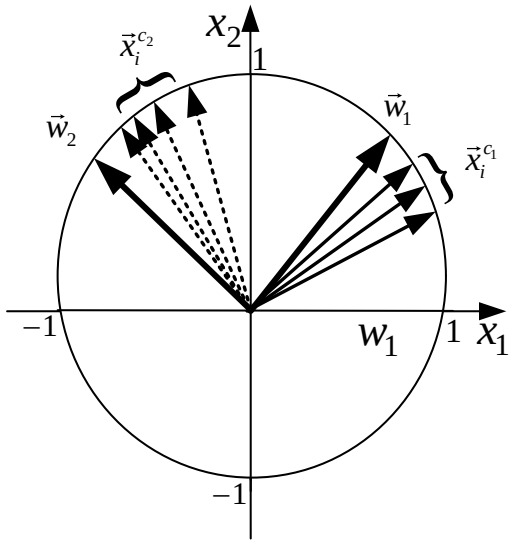

Рис 12.3. Положення вхідних нормованих векторів $\vec{x}_i^{c_i}$ та початкові положення векторів ваг $\vec{w}_i$

Допустимо, першим на вхід мережі подається вектор $\vec{x}_1^{c_1}$ з множини c_1. Очевидно, його векторний добуток з $\vec{w}_1$ буде більшим за векторний добуток з $\vec{w}_2$, тому $y_1 > y_2$ і перший нейрон буде „переможцем”. Його вихід приймається рівним 1 а виходи решти нейронів вважаються рівними нулю.

Далі використовується алгоритм навчання як і для шару Ойа [1], з врахуванням значень виходів. Тоді ваги нейронів, котрі програли, не коректуються (бо для них $y_i = 0$), а для „переможця” величина корекції вектора ваг визначається наступним чином:

$\Delta\vec{w}_j = \eta y_j(\vec{x} - \sum_k y_k \vec{w}_k) = \eta y_j(\vec{x} - y_j \vec{w}_j) = \eta(\vec{x} - \vec{w}_j)$. У випадку перемоги першого нейрона матимемо:

$$\begin{aligned} \Delta w_{11} &= \eta(x_1 - w_{11}) \\ \Delta w_{21} &= \eta(x_2 - w_{21}) \end{aligned}.$$

Згідно цього алгоритму прирости ваг будуть коректувати вектор ваг таким чином, щоб він співпадав за напрямком з вхідним вектором.

Якщо подати вхідний вектор з другої множини c_2, то „переможцем" буде другий нейрон і буде коректуватись тільки вектор ваг другого нейрона $\vec{w}_2$. Очевидно, при подачі серії векторів з обох множин, вектори ваг нейронів будуть орієнтовані в напрямках близьких до векторів математичних сподівань множин c_1 та c_2. Отже, після навчання мережа буде видавати на виході сигнал $\vec{y} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, якщо вхідний вектор належить множині сигналів c_1 і сигнал $\vec{y} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$, якщо вхідний вектор належить множині c_2. Іншими словами, мережа проведе кластеризацію даних. З другого боку, таку процедуру можна назвати оцифруванням сигналу.

У деяких літературних джерелах такого типу мережі (нейрони) називають мережами Кохонена (на ім'я фінського науковця – автора такого типу мереж). Мережі такого типу і алгоритми їх навчання мають дві слабкі сторони:

- часто ми не знаємо на скільки класів можна розбити вхідні дані і тому не можемо адекватно вибрати структуру мережі (кількість нейронів у шарі).
- постає проблема вибору початкових напрямків ваг. Може статися так, що внаслідок невдалого вибору початкових значень ваг деякі нейрони завжди будуть програвати і по-суті будуть „мертвими" (не будуть приймати участі в процедурі кластеризації вхідних даних), а інші – навпаки завжди вигравaтимуть.

Для усунення цих недоліків існують спеціальні алгоритми, котрі в тій чи іншій мірі вільні від згаданих недоліків [3].

Вихідні набори векторів для навчання нейромережі отримуємо з розділу файли команди Teams: Завдання_Дані_лаб12 файл №.xlsx № відповідає номеру студента в журналі обліку ВИКЛАДАЧА.

Завдання

За допомогою нейронної мережі показаної на рисунку 12.2 реалізувати кластеризацію вхідного потоку даних (двовимірних векторів) на три класи.

Програма повинна забезпечити навчання при різних для різних початкових значень ваг нейронів із різними значеннями параметрів:

- Швидкість навчання
- Кількість епох навчання

Зміст звіту по лабораторній роботі:

У звіті слід привести візуалізація вхідних даних.

Привести результати візуалізації при пізних параметрах навчання:

- Візуально представити результат кластеризації
- Вивести знайдені центри кластерів
- Зробити висновки

Література

1. Субботін С. О. Нейронні мережі : теорія та практика: навч. посіб. / С. О. Субботін. – Житомир : Вид. О. О. Євенок, 2020. – 184 с. ISBN 978-966-995-189-2
2. Любунь З. М. Основи теорії нейромереж / З. М. Любунь /: Текст лекцій. – Львів: Видавничий центр ЛНУ імені Івана Франка, 2007. –142 с.
3. Любунь З., Русин Б., Луцик О. Особливість навчання мережі Кохонена на основі методу нейроядерної ентропії при стиску зображень / З. Любунь, Б. Русин, О. Луцик // “Радіоелектр-оніка та інформатика”. –2007. – №1. –С. 69-72.